



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente

Disciplina: Engenharia Econômica e Avaliação de Projetos

Discente: Rodrigo Marcel Araujo Oliveira

Docentes: Ricardo Kalid; Ricardo Uchoa

Orientador: Ângelo Márcio Oliveira Sant'Anna

AGENDA

Contextualização

- Introdução
- Justificativa
- Revisão bibliográfica

Pergunta e Hipótese

Objetivos

Escopo

Metodologia

Resultados esperados da pesquisa

Mapa conceitual

Etapas da pesquisa e cronograma

Avaliação econômica

- Negócio
- Premissas
- Recursos
- Fluxo de caixa
- Indicadores econômicos
- Simulação de Monte Carlo

Conclusões

Considerações

Referências

- A manufatura dos pneus consiste em sete processos (“NEXEN TIRE,” [s.d.]) :

Figura 1 - Processo de refino



Fonte: Processo de refino, (“NEXENTIRE,” [s.d.])

Figura 2 - Processo de extrusão



Fonte: Processo de extrusão, (“NEXENTIRE,” [s.d.])

Figura 3 - Processo de laminação




Fonte : Processo de laminação, (“NEXENTIRE,” [s.d.])

Figura 4 - Processo de talão



Fonte: Processo de talão, (“NEXEN TIRE,” [s.d.])

Figura 5 - Processo de moldagem



Fonte: Processo de modelagem, (“NEXENTIRE,” [s.d.])

Figura 6 - Processo de cura



Fonte: Processo de cura, (“NEXENTIRE,” [s.d.])

- A manufatura dos pneus consiste em sete processos (“NEXEN TIRE,” [s.d.]) :


Figura 7 - Processo de teste e expedição



Fonte: Processo de teste e expedição, (“NEXEN TIRE,” [s.d.])

- A previsão do desempenho do pneu faz parte do planejamento estratégico no processo de manufatura de pneus.
- Modelos de detecção de defeitos para garantia da qualidade de pneus são fundamentais.
- Modelos de aprendizado de máquina vêm ganhando espaço na academia em estudos para investigar padrões não lineares para detecção automática de defeitos em pneus.

Figura 8 - Anatomia do pneu



Fonte: Anatomia do pneu, segundo a ABNT NBR 224 que defini a terminologia para pneus,

- Cerca de 800 milhões de pneus inservíveis são descartados em todo o mundo anualmente (TSANG, 2010).
- No Brasil, esses pneus inservíveis acabam servindo de criadouros para o mosquito *Aedes Argypiti*, transmissor de dengue, *Zika* e *Chikungunya*.
- É um dos principais fatores que determinam a segurança do veículo.
- Detecção de falhas -> diminuição de custos.

Figura 9 - Pneus inservíveis



Fonte: Pneus inservíveis, (“Reciclagem - Utep,” [s.d.])



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- Método de previsão de vida útil de pneus baseado em processamento de imagens e aprendizado de máquina (Zhu et al., 2021).
- Algoritmos de aprendizado de máquina envolvendo mistura de variáveis numéricas e categóricas para previsão de desempenho de pneus (Gutierrez-Gomez et al., 2020).
- Prever a tensão triaxial de contato pneu-estrada em (Li et al., 2021)



Pergunta

- Quais modelos de aprendizado de máquina são capazes de avaliar o desempenho dos pneus em sistemas produtivos de manufatura inteligente de pneus?

Hipótese

- Os modelos de aprendizado de máquina não são capazes de avaliar o desempenho de pneus em sistemas produtivos de manufatura.



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- Investigar a relação entre as características das variáveis explicativas e as variáveis respostas.
- Analisar o desempenho de diferentes modelos de aprendizado de máquinas para classificação do desempenho do pneu.
- Identificar quais são as variáveis explicativas na composição dos pneus que tem maior impacto na variável resposta.
- Analisar quais são os limiares de cada variável explicativa na fronteira de classificação do desempenho do pneu.



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- Dados provenientes de um estudo realizado em uma indústria multinacional
- Pneus para carros de passeio e caminhões.
- Abordagem quantitativa
- Modelagem estatística e computacional
- Nível de Maturidade Tecnológica (TRL/MRL): TRL/MRL₁ (MANKINS, 1995)

- Dados provenientes do processo de uniformidade de pneus.
- A variável resposta desse estudo é o desempenho do pneu: A, B e C.
- Tamanho da amostra: 107 observações; 46 (A); 46 (B); 15 (C).

Figura 10 - Processo de uniformidade do pneu




Fonte: Processo de uniformidade do pneu (“Always on the safe side ZF Test Systems for tires,” [s.d.])

- Variáveis explicativas:

- Flutuação da força radial (RFV);
- Flutuação de força lateral (LFV);
- Excentricidade radial (RRO);
- Efeito de conicidade (CONICITY);
- Efeito angular (PLY);
- Força radial 1º-2º harmônico (H1RFV-H2RFV);
- Força lateral 1º harmônico (H1LFV);
- Excentricidade radial 1º harmônico (H1RRO);
- Emenda de tampa (CAPSPLICE).

Figura 11 - Sistema de eixos coordenados e forças que actuam num pneu



Fonte: Sistema de eixos coordenados e forças que actuam num pneu, ("Parâmetros de Medida da Uniformidade de um Pneu Vulcanizado | Ciência e Tecnologia da Borracha Ciência e Tecnologia da Borracha," [s.d.])

- Técnicas de amostragem: Hold-out e Leave-one-out (Arlot & Celisse, 2010)
- Ajuste de hiperparâmetros: GridSearchCV (Ahmad et al., 2022)
- Matriz cruzada (Deng et al., 2016)
- Métrica de avaliação: Acurácia; Precision; Recall; F score; AUC; etc.

Figura 12 - Matriz cruzada

		Classe Predita		
		C_1	\dots	C_n
Classes Real	C_1	N_{11}	\dots	N_{1n}
	\vdots	\vdots	\ddots	\vdots
	C_n	N_{n1}	\dots	N_{nn}

Fonte: Matriz cruzada, (Autor, 2022)

Figura 13 - Métricas de avaliação

$$AC = \frac{\sum_{i=1}^n N_{ii}}{\sum_{i=1}^n \sum_{j=1}^n N_{ij}}$$

$$PREC_i = \frac{N_{ii}}{\sum_{j=1}^n N_{ji}}$$


$$REC_i = \frac{N_{ii}}{\sum_{j=1}^n N_{ij}}$$

$$F\ score_i = \frac{2 \times PREC_i \times REC_i}{PREC_i + REC_i}$$

Fonte: Métricas de avaliação, (Autor, 2022)

- Support Vector Machine (SVM), (Cortes et al., 1995).


Figura 14 - Margem do SVM



Fonte: Support Vector Machine, (Autor, 2022)

- Multi-layer Perceptron (MLP), (FACELI et al., 2011).


Figura 15 - Perceptron multicamadas



Fonte: Perceptron multicamadas, (SILVA et al., 2010)

- Random Forest (RF), (Breiman, 2001)


Figura 16 - Diagrama do RF



Fonte: Diagrama do RF, (NAIN; GARG; KUMAR, 2018)

- Gauss Process Classification (GPC), (Taki et al., 2018)

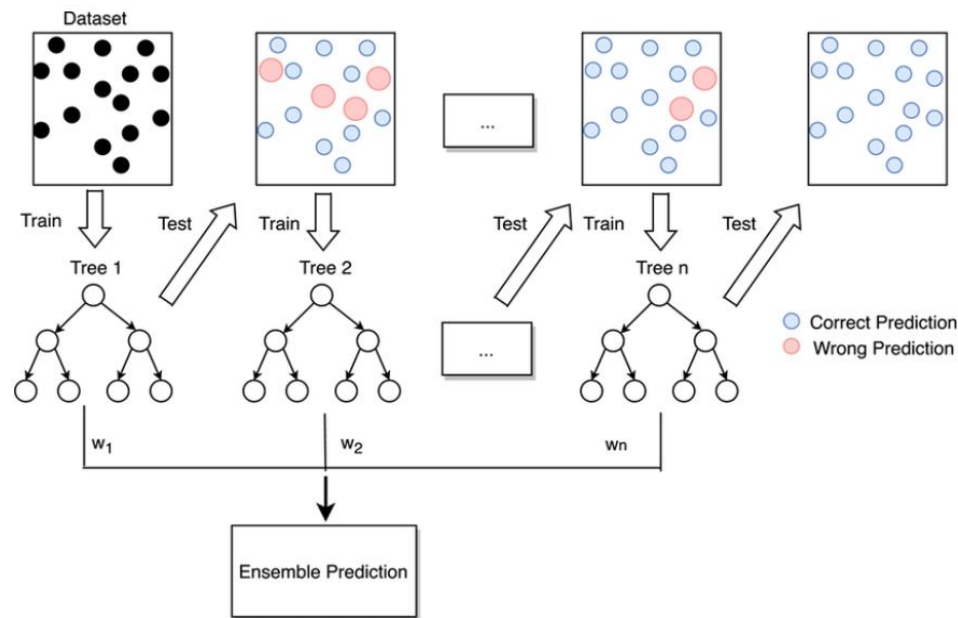
Figura 17 - Limites de decisão de um GPC



Fonte: Limites de decisão, (SNELL; ZEMEL, [s.d.])

- Gradient Boosting Machine (GBM), (James et al., 2013)


Figura 18 - Diagrama do GBM



Fonte: Diagrama do Gradient Boosting, (ZHANG et al., 2021)

- Regressão Logística (LR), (Hastie et al., 2009)

Figura 19 - Função Logit da LR



Fonte: Logit da LR, ("How To Build Logistic Regression Model In R," [s.d.])

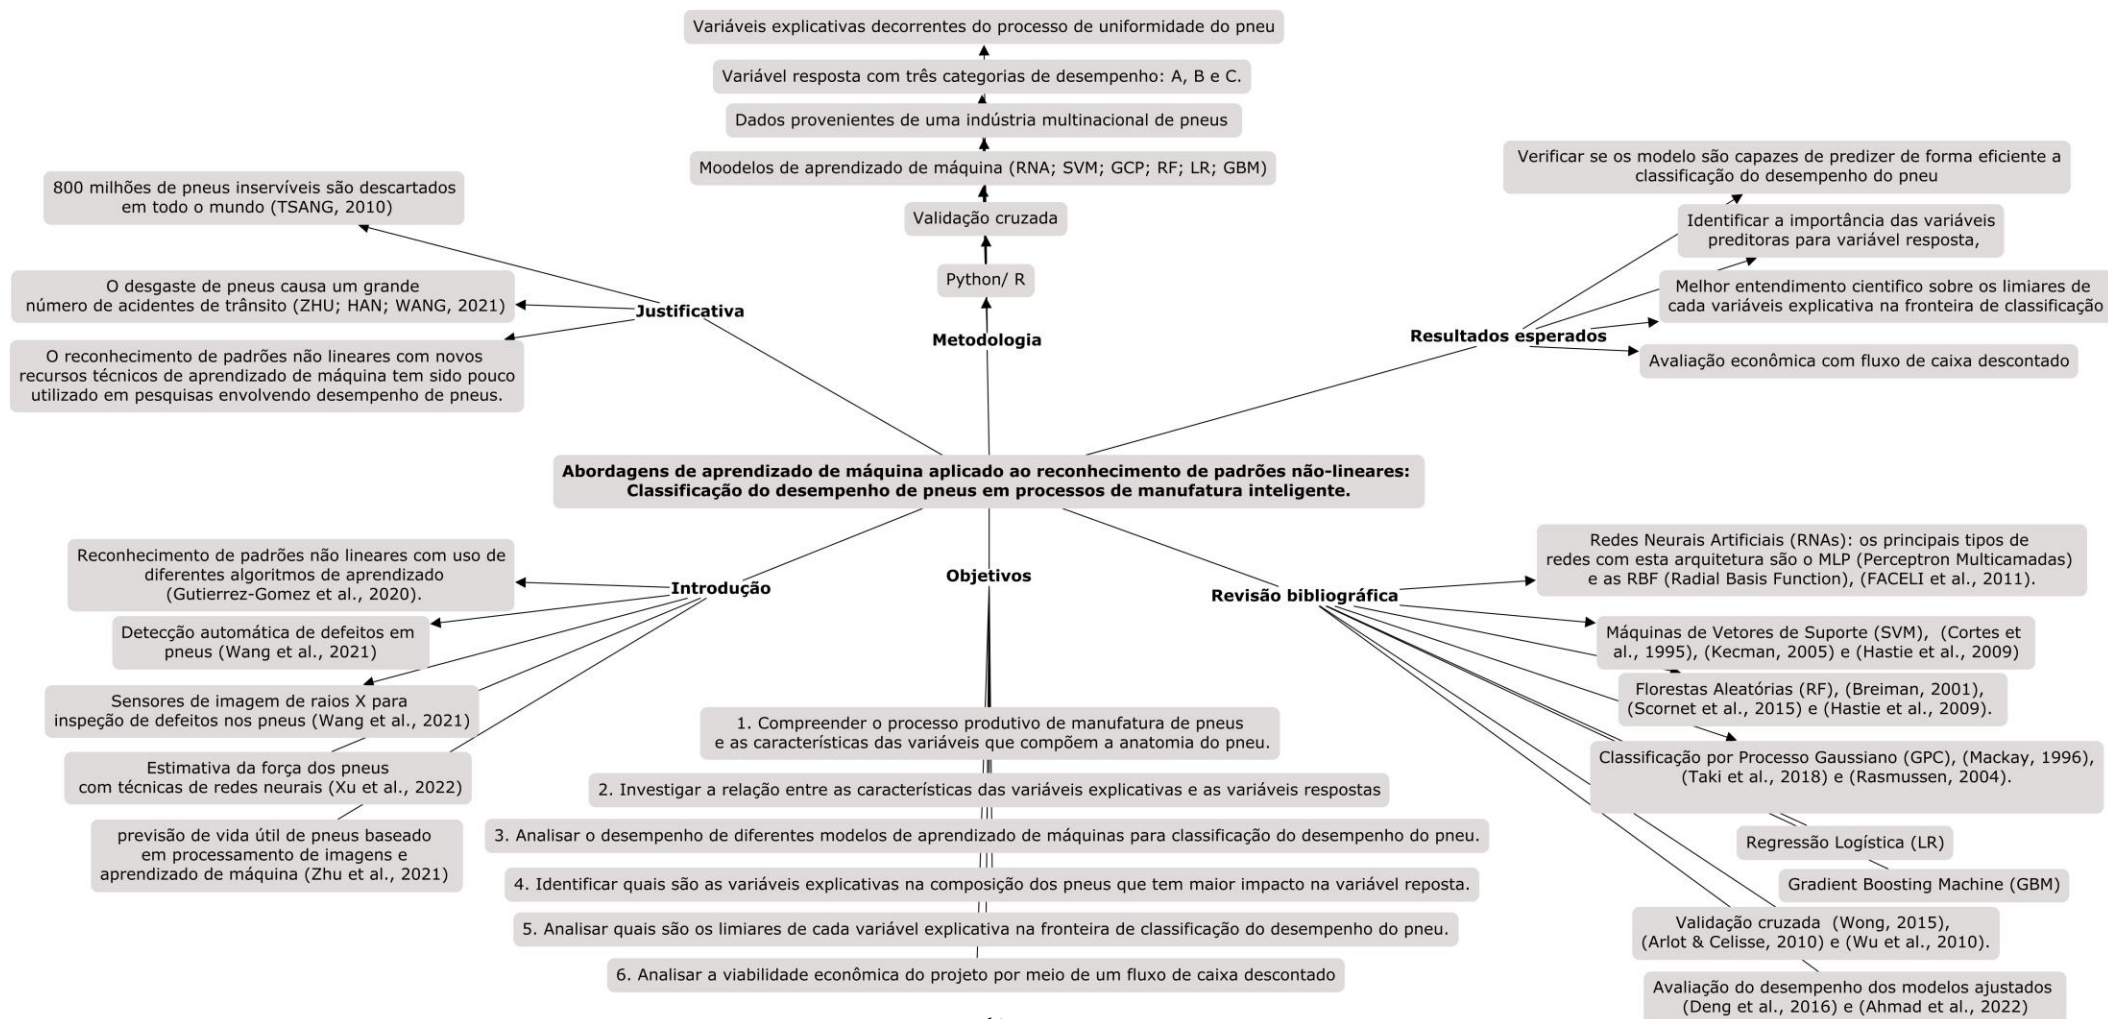


Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- Compreender a relação entre as características das variáveis explicativas e as variáveis respostas.
- Averiguar se modelos de aprendizado de máquina são capazes de avaliar o desempenho de pneus em sistemas produtivos de manufatura.
- Identificar quais são as variáveis explicativas na composição dos pneus que tem maior impacto na variável repostada.
- Analisar quais são os limiares de cada variável explicativa na fronteira de classificação do desempenho do pneu.

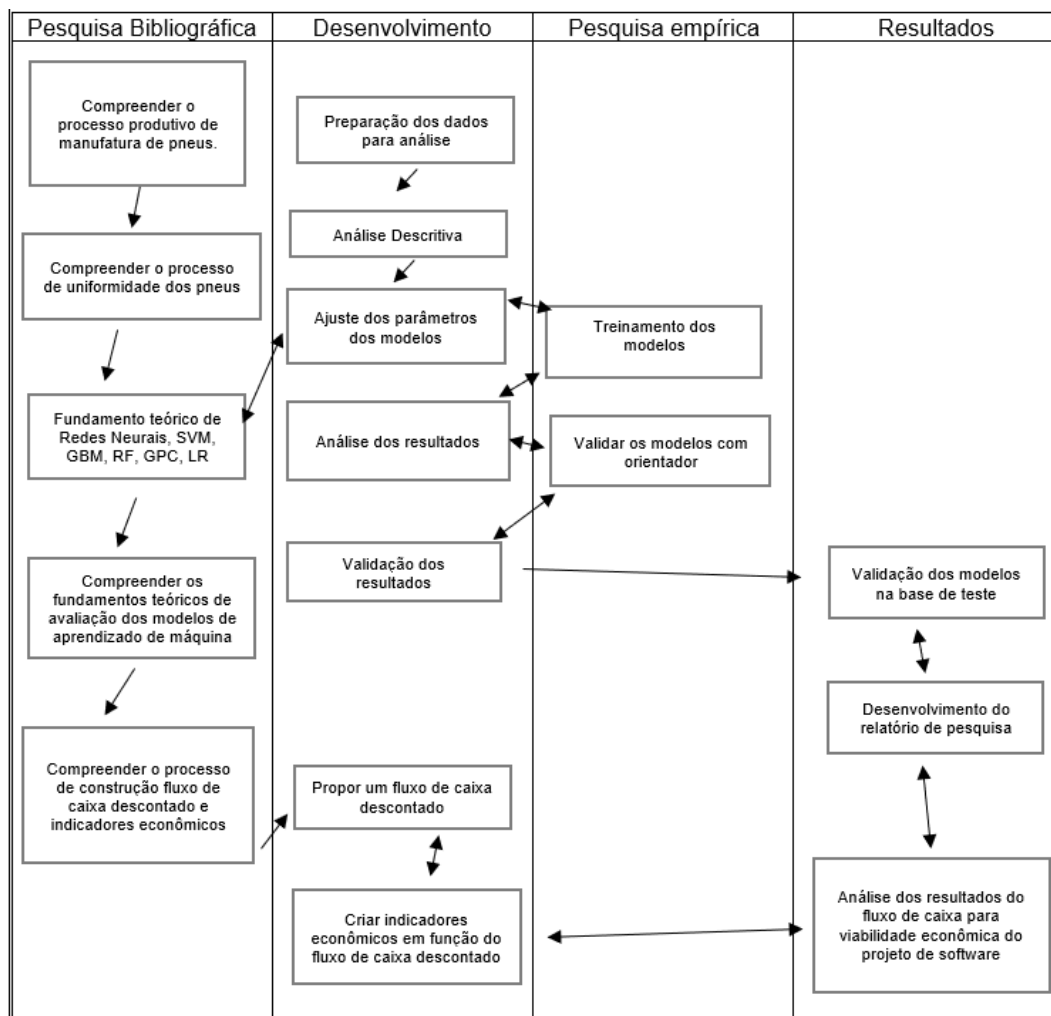
Figura 20 - Mapa conceitual



Fonte: (Autor, 2022)

Mapa conceitual

Figura 20 - Etapas da pesquisa



Fonte: (Autor, 2022)

Figura 21 - Cronograma

Meses		0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
Etapas																										
1	Realização das disciplinas	x	x	x	x	x	x	x	x	x	x	x	x	x												
2	Elaboração do anteprojeto de pesquisa	x	x	x	x	x	x																			
3	Metodologia:																									
3.1	Compreender o processo produtivo de manufatura de pneus							x	x	x	x	x	x	x	x	x	x	x								
3.1.1	Estrutura do pneu							x																		
3.1.2	Aspectos econômicos da Indústria							x	x																	
3.1.3	Processo de uniformidade do pneu							x																		
3.2	Análise descritiva e preparação dos dados							x	x	x																
3.2.1	Preparação dos dados							x	x	x																
3.2.2	Análise descritiva dos dados							x	x	x																
3.2.3	Amostragem							x	x	x																
3.3	Modelagem: RNA; SVM; RF; GPC; GBM; LR							x	x	x	x	x	x	x	x	x	x	x								
3.3.1	Ajuste dos parâmetros por validação cruzada							x	x	x	x	x	x	x	x	x	x	x								
3.3.2	Análise de desempenho							x	x	x	x	x	x	x	x	x	x	x								
3.3.3	Avaliação da capacidade de generalização do modelo							x	x	x	x	x	x	x	x	x	x	x								
3.4	Comparações dos resultados dos modelos							x	x	x	x	x	x	x	x	x	x	x								
3.5	Compreender quais são as variáveis explicativas que têm o maior impacto na variável resposta																		x	x	x					
3.6	Investigar os limiares de cada variável																		x	x	x					
3.7	Realização dos seminários																									
3.7.1	Realização da qualificação																									
3.7.2	Elaboração de artigos ou de outros produtos																									
3.8	Elaboração do trabalho de conclusão																									
3.9	Defesa do TCC																									
4	Ajuste final do TCC																									

Fonte: (Autor, 2022)

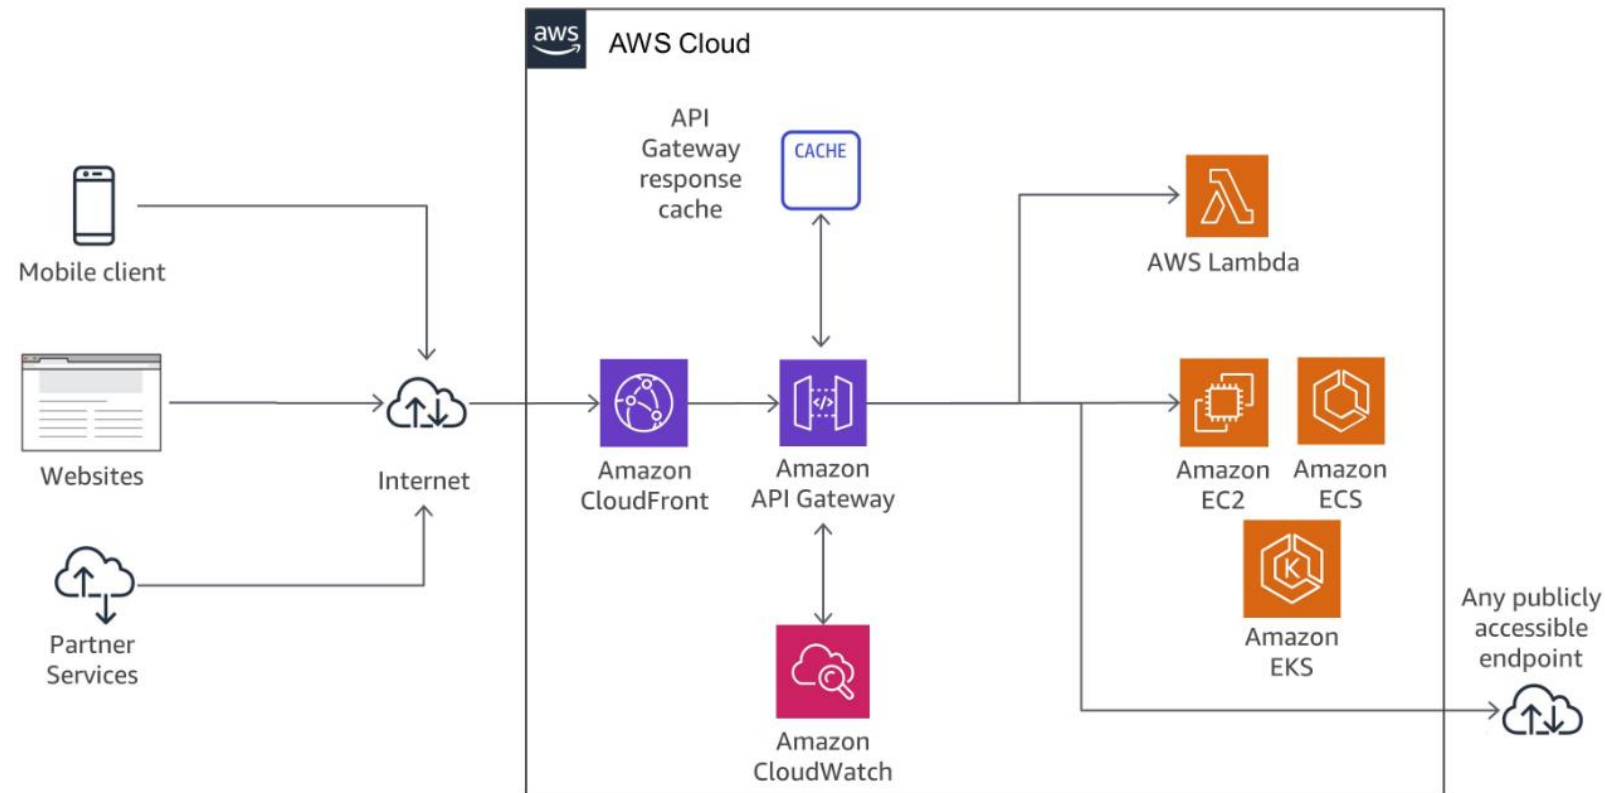


Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- Empresa de Software (Startup) para avaliar o desempenho de pneus.
- Produto: plataforma de modelos estatísticos para avaliação de desempenho de pneus.
- Unidade funcional: Interface de Programação de Aplicação (API) por requisição gerada.
- Preço de venda: R\$ 2,00.
- Média anual de vendas de pneus no Brasil: 56 Milhões (“VENDAS TOTAIS DE PNEUS CRESCEM 0,4%, MAS SEGUE ACUMULANDO QUEDA NO ANO COMPARADO EM 2021 | ANIP - Associação Nacional da Indústria de Pneumáticos,” [s.d.]).

Figura 22 - Implementação de APIs



Fonte: (“Implementação de APIs - Implementação de microsserviços na AWS,” [s.d.])



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



Tabela 1 - Descrição dos recursos

Tabela Investimento_I: Recursos e seus custos, as unidades monetárias estão em R\$.

Descrição dos Recursos	Quantidades de recursos	Quantidade de horas semanais	Custo por horas	Custo de aquisição	Custo total no ano 0
Aluno de mestrando	1	40	9.375	1500	18000
Orientador	1	10	93.750	3750	45000
Administrador	1	40	37.500	6000	72000
Coordenador de projetos	1	40	75.000	12000	144000
Desenvolvedor de software Junior	2	40	34.375	5500	132000
Desenvolvedor de software Pleno	1	40	45.000	7200	86400
Desenvolvedor de software Sênior	1	40	55.000	8800	105600
Gerente comercial	1	40	50.000	8000	96000
Técnico de informatica	2	40	15.625	2500	60000
Escritório (coworking salvador)	1			5500	66000
Equipamentos de escritório	12			300	3600
Computador + acessórios	12			4500	54000
Infraestrutura de software (AWS)	1			2880	34560
Consultoria para Patente	1			50000	50000
Consultoria para desenvolvimento do site da empresa	1			30000	30000
Investimento na marca				70000	70000
Software livre - Python/ R				0	0
Software livre - Project Libre				0	0
Software livre - Libreoffice				0	0
Software livre - Github/ Gitlab				0	0
Base de dados - Capes				0	0
				Total	1067160

Fonte: (Autor, 2022)

Tabela 2 - Premissas do fluxo de caixa

Premissas assumidas.		
Período base (unidade de tempo básica)	ano	
Unidade funcional (base de cálculo):	API	de requisição gerada
Inflação	0.0	% / ano
Quantidade de períodos cobertos pelo capital de giro	1.0	ano(s) que deve ser menor ou igual a 4
Impostos proporcionais federais (IPI, PIS/CONFINS etc.)	8.0	% sobre a receita total
Impostos proporcionais estaduais (ICMS etc.)	2.5	% sobre a receita total
Impostos proporcionais municipais (ISS etc.)	0.0	% sobre a receita total
Investimento máximo em PD&I (veja capital de giro)	10.0	% da receita líquida
Investimento máximo em marketing (veja capital de giro)	5.0	% da receita líquida
Outras despesas, por exemplo, causas trabalhistas, multas	5.0	% do custo operacional
Taxa de imposto de renda sobre o LAIR	10.0	%
Contribuição social sobre o LAIR	7.5	%
Outras taxas ou impostos ou tributos sobre o LAIR	5.0	%
Tempo de retorno mínimo	3.0	ano (s)
Empréstimo para capital de giro (CG)	200000	R\$
Empréstimo para investimento em bens de capital	100000	R\$
Quantidade de períodos para quitar o empréstimo	5	Obs.: deve ser menor ou igual a 10
Período de carência para pagamento do juros do empréstimo	2	ano(s), apenas para período inteiro de carência
Período de carência para pagamento do principal do empréstimo	2	ano (s), deve ser maior ou igual a carência para os juros
Taxa de juros, inclui a inflação	6.0	% por ano

Fonte: Adaptado de (KALID, 2022).



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



Tabela 3 - Receitas Brutas ao longo do tempo.

Tabela RB: receitas brutas ao longo do tempo, as unidades monetárias estão em R\$.							Cenário 1	Cenário 2	Cenário 3
Período	Receita Não Operacional	Receita total sobre vendas	Consumo da API			Cenário escolhido:	0	0	1
			Valor unitário consumo por requisição de API	Venda por período (ano)	Sub-total / R\$		Venda mensal / consumo	Venda mensal / consumo	Venda mensal / consumo
0	0	0	2	0	0	0	0	0	0
1	0	2400000	2	1200000	2400000	100000	50000	75000	100000
2	0	4800000	2	2400000	4800000	200000	100000	150000	200000
3	0	7200000	2	3600000	7200000	300000	200000	250000	300000
4	0	9600000	2	4800000	9600000	400000	300000	350000	400000
5	0	12000000	2	6000000	12000000	500000	400000	450000	500000
6	0	14400000	2	7200000	14400000	600000	500000	550000	600000
7	0	16800000	2	8400000	16800000	700000	600000	650000	700000
8	0	19200000	2	9600000	19200000	800000	700000	750000	800000
9	0	21600000	2	10800000	21600000	900000	800000	850000	900000
10	0	24000000	2	12000000	24000000	1000000	900000	950000	1000000

Fonte: Adaptado de (KALID, 2022).



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



Tabela 4 - Fluxo de caixa descontado.

Tabela FCP: fluxo de caixa do projeto, as unidades monetárias estão em R\$.												
	Período / ano ---->	0	1	2	3	4	5	6	7	8	9	10
Receita bruta ou receita total	RB = RV + RNO	0	2400000	4800000	7200000	9600000	12000000	14400000	16800000	19200000	21600000	24000000
Receita Não Operacional	RNO	0	0	0	0	0	0	0	0	0	0	0
Receita total sobre vendas	RV = q . Pu	0	2400000	4800000	7200000	9600000	12000000	14400000	16800000	19200000	21600000	24000000
Quantidade vendida / unidades	q	0	1200000	2400000	3600000	4800000	6000000	7200000	8400000	9600000	10800000	12000000
Preço unitário / (R\$/API)	Pu	2	2	2	2	2	2	2	2	2	2	2
Impostos proporcionais (ISS, ICMS, IPI, PIS, CONFINS etc.) total	IPp = IPF + IPE + IPM	0	252000	504000	756000	1008000	1260000	1512000	1764000	2016000	2268000	2520000
Impostos proporcionais federais (IPI, PIS/CONFINS etc.)	IPF	0	192000	384000	576000	768000	960000	1152000	1344000	1536000	1728000	1920000
Impostos proporcionais estaduais (ICMS etc.)	IPE	0	60000	120000	180000	240000	300000	360000	420000	480000	540000	600000
Impostos proporcionais municipais (ISS etc.)	IPM	0	0	0	0	0	0	0	0	0	0	0
Receita líquida	RL = RT - IPt	0	2148000	4296000	6444000	8592000	10740000	12888000	15036000	17184000	19332000	21480000
Custos e investimentos	CI = IT + CO	1151388	1055214	1272477	1462490	1622651	2087688	2304567	2575689	2775480	3433963	3627607
Investimento total	IT = IBC + IBE + IBI + PD&I + MKT	207600	87610	103720	119830	135940	152050	168160	184270	200380	216490	232600
Custo variável	CV	36288	65318	130637	195955	261274	326592	391910	457229	522547	587866	653184
Custo fixo	CF	907500	902286	1038120	1146705	1225438	1609046	1744497	1934190	2052552	2629607	2741823
Lucro operacional ou LAJIRDA ou EBITDA	LO = RL - CI	-1151388	1092786	3023523	4981510	6969349	8652312	10583433	12460311	14408520	15898037	17852393
Depreciações (somatório)	Ds	30000	15520	15520	15520	15520	15520	15520	15520	15520	15520	15520
Somatório da amortização (principal) de empréstimos e outros dedutíveis do IR	SAD = Emp + OD	47189	48380	114850	126930	137720	163970	178039	119571	128755	160874	169750
Lucro antes do juros, imposto de renda e das contribuições sociais (LAJIR)	LAJIR = LO - (DS+SAD)	-1228577	1028885	2893153	4839060	6816109	8472822	10389873	12325220	14264245	15721643	17667123
Juros de empréstimos pagos a credores	JE	0	0	19080	15695	12107	8304	4273	0	0	0	0
Lucro antes do imposto de renda e das contribuições sociais (LAIR)	LAIR = LAJIR -JE	-1228577	1028885	2874073	4823365	6804001	8464518	10385600	12325220	14264245	15721643	17667123
Total de impostos e taxas sobre o LAIR	TT = IR+CS+OT	0	231499	646666	1085257	1530900	1904516	2336760	2773174	3209455	3537370	3975103
Imposto de renda, % sobre o LAIR	IR	0	102889	287407	482337	680400	846452	1038560	1232522	1426425	1572164	1766712
Contribuições sociais, % sobre o LAIR	CS	0	77166	215555	361752	510300	634839	778920	924391	1069818	1179123	1325034
Outras taxas ou impostos ou tributos sobre o LAIR	OT	0	51444	143704	241168	340200	423226	519280	616261	713212	786082	883356
Lucro líquido	LL = LAIR - TT	-1228577	797386	2227407	3738108	5273101	6560001	8048840	9552045	11054790	12184274	13692020
Capital de giro disponível			200000	3224793	9190307	18201516	30034618	44643460	62244345	82851181	106090245	131966539
Capital de giro necessário, sem considerar a reserva para depreciação			1055214	1272477	1462490	1622651	2087688	2304567	2575689	2775480	3433963	3627607
Capital de giro necessário, considerando a reserva para depreciação e o lucro líquido positivo			1039694	1256957	1446970	1607131	2072168	2289047	2560169	2759960	3418443	3612087
Diferença entre o capital de giro disponível e o necessário	CGn = Emp.p-CGn		-839694	1967836	7743337	16594385	27962450	42354412	59684176	80091221	102671802	128354452
Mínimo valor da diferença entre o empréstimo disponível e o capital de giro necessário			-839694									


Fonte: Adaptado de (KALID, 2022).

Tabela 5 - Indicadores econômicos.

Tabela IE: indicadores econômicos para diferentes cenários.							
Cenários -->		Menor TMA		TMA intermediária		Maior TMA	
TMA		4.0%		6.0%		8.0%	
Investimento		1407716		1254067		1124034	
R	VP sem Inv.	53646021		46106461		39811788	
e	VPL	52238305	Viável	44852394	Viável	38687754	Viável
t	VPLp	6440510	Viável	6094003	Viável	5765616	Viável
o	IL ou IBC	2.2	Viável	2.2	Viável	2.1	Viável
r	ROIp	8.1%	Viável	8.0%	Viável	7.9%	Viável
n	ROI	12.4%	Viável	14.5%	Viável	16.6%	Viável
R	TIR	145.9%	Viável	145.9%	Viável	145.9%	Viável
i	TIRm	12.4%	Viável	14.5%	Viável	16.6%	Viável
s	TIR / TMA	36.5	Viável	24.3	Viável	18.2	Viável
c	TIRm / TMA	3.1	Viável	2.4	Viável	2.1	Viável
o	TR-RB/ (ano)	1.1	Viável	1.1	Viável	1.1	Viável
	TR-RB / N	10.9%		11.0%		11.0%	
	TR-DL/ (ano)	2.20	Viável	2.22	Viável	2.23	Viável
	TR-DL / N	22.0%		22.2%		22.3%	
	TR-LL / (ano)	2.22	Viável	2.24	Viável	2.26	Viável
	TR-LL / N	22.2%		22.4%		22.6%	

Fonte: Adaptado de (KALID, 2022).

Figura 23 - Distribuição da receita anual



Fonte: (Autor, 2022)


$$f(z; k; \theta) = \frac{z^{k-1} e^{-\frac{z}{\theta}}}{\theta^k \Gamma(k)} \quad z, k, \theta > 0$$

$$Z \sim \text{Gama}(k = 9500, \theta = 200)$$

Média: 1 899 827
Mediana: 1 899 629
Desvio padrão: 19 507

Número de interações: 30 000

Figura 24 - Distribuição da taxa de crescimento anual da receita




Fonte: (Autor, 2022)

$$f(y; \mu; \sigma) = \frac{e^{-\frac{1}{2} \left(\frac{\ln(y) - \mu}{\sigma} \right)^2}}{y \sigma \sqrt{2\pi}} \quad \mu \in \mathbb{R}, \quad \sigma, y > 0$$

$$Y \sim \text{LogNormal}(\mu = -\frac{3}{2}, \sigma^2 = \frac{1}{100})$$

Média: 0,22
Mediana: 0,22
Desvio padrão: 0,02

Figura 25 - Distribuição da taxa mínima de atratividade



Fonte: (Autor, 2022)

$$f(x; \mu; \sigma) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1} \quad 0 \leq x \leq 1, \quad \alpha, \beta > 0$$

$$X \sim \text{Beta}(\alpha = 7, \beta = 70)$$

Média: 0,09
Mediana: 0,08
Desvio padrão: 0,03

Taxa de crescimento da receita (TCR)

$$TCR_{ij} = Y, \quad i \in [1, 10], \quad j \in [1, 30\,000]$$

Receita Bruta (RB)

$$RB_{ij} = \begin{cases} 0, & i = 0, \quad j \in [1, 30\,000] \\ E[Z], & i = 1, \quad j \in [1, 30\,000] \\ RB_{(i-1)j}(1 + TCR_{ij}), & i \in [2, 10], \quad j \in [1, 30\,000] \end{cases}$$

Fluxo de caixa descontado (FCD)

$$FCD_{ij} = \begin{cases} LL_{ij} = RB_{ij} - IPt_i - CI_i - DS_i - SAD_i - JE_i - TT_i, & i \in [0, 1], \quad j \in [1, 30\,000] \\ LL_{ij} = RB_{(i-1)j}(1 + TCR_{ij}) - IPt_i - CI_i - DS_i - SAD_i - JE_i - TT_i, & i \in [2, 10], \quad j \in [1, 30\,000] \end{cases}$$


Taxa mínima de atratividade (TMA)

$$TMA_j = E[X], \quad j \in [1, 30\,000]$$

Valor Presente Líquido (VPL)

$$VPL_j = FCD_{0j} + \sum_{i=1}^{n=10} \frac{FCD_{ij}}{(1 + TMA_j)^i}, \quad i \in [1, 10], \quad j \in [1, 30\,000]$$

Figura 25 - Distribuição do VPL



Fonte: (Autor, 2022)


Medidas resumo

Média: 9 796 681
Mediana: 9 567 978
Desvio padrão: 2 168 243

Taxa Interna de Retorno (TIR)

$$VPL_j = FCD_{0j} + \sum_{i=1}^{n=10} \frac{FCD_{ij}}{(1 + TIR_j)^i} = 0, \quad i \in [1, 10], \quad j \in [1, 30\,000]$$

Figura 26 - Distribuição da TIR



Fonte: (Autor, 2022)

Medidas resumo

Média: 0,63
Mediana: 0,63
Desvio padrão: 0,05



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- A avaliação econômica em função das premissas adotadas demonstra que o projeto proposto é viável.
- Foi possível criar diversos cenários de receita, taxa de crescimento e TMA em função de distribuições de probabilidade para avaliação dos indicadores econômicos TIR e VPL.
- Conforme as simulações de Monte Carlo a média do VLP é positiva e o TIR apresenta valores superiores a TMA.



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- Análise disponível em: <https://github.com/roaraujo/engenharia-economica-avaliacao-projetos>



- ACOSTA, S. M. et al. Relevance vector machine with tuning based on self-adaptive differential evolution approach for predictive modelling of a chemical process. **Applied Mathematical Modelling**, v. 95, p. 125–142, 1 jul. 2021.
- Always on the safe side ZF Test Systems for tires. [s.d.]. ARLOT, S.; CELISSE, A. A survey of cross-validation procedures for model selection.
- ARLOT, S.; CELISSE, A. A survey of cross-validation procedures for model selection. <https://doi.org/10.1214/09-SS054>, v. 4, n. none, p. 40–79, 1 jan. 2010.
- BREIMAN, L. Heuristics of instability and stabilization in model selection. <https://doi.org/10.1214/aos/1032181158>, v. 24, n. 6, p. 2350–2383, 1 dez. 1996.
- BREIMAN, L. Random Forests. v. 45, p. 5–32, 2001.
- CORTES, C.; VAPNIK, V.; SAITTA, L. Support-vector networks. **Machine Learning 1995 20:3**, v. 20, n. 3, p. 273–297, set. 1995.
- DE CASTRO, L. N. Fundamentals of Natural Computing : Basic Concepts, Algorithms, and Applications. **Fundamentals of Natural Computing**, 2 jun. 2006.



- DEMŠAR, J. Statistical Comparisons of Classifiers over Multiple Data Sets. **Journal of Machine Learning Research**, v. 7, p. 1–30, 2006.
- GUTIERREZ-GOMEZ, L.; PETRY, F.; KHADRAOUI, D. A Comparison Framework of Machine Learning Algorithms for Mixed-Type Variables Datasets: A Case Study on Tire-Performances Prediction. **IEEE Access**, v. 8, p. 214902–214914, 2020.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning. Springer Series in Statistics. 2009.
- **How To Build Logistic Regression Model In R.** Disponível em: <<https://www.analyticsvidhya.com/blog/2015/10/basics-logistic-regression/>>. Acesso em: 20 jun. 2022.
- **Implementação de APIs - Implementação de microsserviços na AWS.** Disponível em: <https://docs.aws.amazon.com/pt_br/whitepapers/latest/microservices-on-aws/api-implementation.html>. Acesso em: 27 jun. 2022.
- JAMES, G. et al. Statistical Learning. p. 15–57, 2013.
- KECMAN, V. Support Vector Machines – An Introduction. p. 1–47, 22 abr. 2005.



Abordagens de aprendizado de máquina aplicado ao reconhecimento de padrões não-lineares: Classificação do desempenho de pneus em processos de manufatura inteligente



- LEE, S. K. et al. Prediction of tire pattern noise in early design stage based on convolutional neural network. **Applied Acoustics**, v. 172, 15 jan. 2021.
- LI, X.; GUO, M.; ZHOU, X. A multivariate multiple regression analysis of tire-road contact peak triaxial stress by using machine learning methods. **Mechanics of Advanced Materials and Structures**, 2021.
- MACKAY, D. J. C. INTRODUCTION TO GAUSSIAN PROCESSES. 1996.
- MANKINS, J. C. TECHNOLOGY READINESS LEVELS. 1995.
- MEURER, A. P. S.; LOBO, D. D. S. CARACTERIZAÇÃO DA LOGÍSTICA DO SISTEMA AGROINDUSTRIAL (SAG) DA CANA-DE-AÇÚCAR NO CENTRO-OESTE DO BRASIL DOI - 10.5752/P.1984-6606.2015v15n39p45. **Revista Economia & Gestão**, v. 15, n. 39, 8 jul. 2015.
- NAIN, S. S.; GARG, D.; KUMAR, S. Performance evaluation of the WEDM process of aeronautics super alloy. **Materials and Manufacturing Processes**, v. 33, n. 16, p. 1793–1808, 10 dez. 2018.
- **NEXEN TIRE**. Disponível em:
<https://www.nexentire.com/br/information/tire_information/basic_sense/process.php>. Acesso em: 19 jun. 2022.



- **Parâmetros de Medida da Uniformidade de um Pneu Vulcanizado | Ciência e Tecnologia da Borracha** e **Tecnologia da Borracha**. Disponível em: <<https://www.ctborracha.com/borracha-sintese-historica/aplicacoes/pneus/ensaios-no-fabrico-de-pneus/parametros-de-medida-da-uniformidade-de-um-pneu-vulcanizado/>>. Acesso em: 19 jun. 2022.
- PROBST, P.; BOULESTEIX, A.-L. To Tune or Not to Tune the Number of Trees in Random Forest. **Journal of Machine Learning Research**, v. 18, p. 1–18, 2018.
- KALID, R. A. FCD_e_Indicadores_economicos.xlsx. 2022. Disponível em: <<https://www.dropbox.com/sh/82s5959ougolwhn/AADTeEGn5tczkTUr1RMw3AgMa/Planilhas?dl=0&lst=>>>. Acesso em: 05 jun 2022.
- RAJESWARI, M. et al. Detection of tyre defects using weighted quality-based convolutional neural network. **Soft Computing**, v. 26, n. 9, p. 4261–4273, 1 maio 2022.
- RASMUSSEN, C. E. Gaussian Processes in Machine Learning. **Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)**, v. 3176, p. 63–71, 2004.
- **Reciclagem - Utep**. Disponível em: <<https://www.utep.com.br/reciclagem.php>>. Acesso em: 19 jun. 2022.



- SCORNET, E.; BIAU, G.; VERT, J.-P. CONSISTENCY OF RANDOM FORESTS 1. **The Annals of Statistics**, v. 43, n. 4, p. 1716–1741, 2015.
- **Secretaria de Estado da Saúde - Para eliminar possíveis focos do Aedes aegypti, SC terá uma semana de mobilização para recolhimento de pneus.** Disponível em: <<https://www.saude.sc.gov.br/index.php/noticias-geral/todas-as-noticias/1641-noticias-2019/10637-para-eliminar-possiveis-focos-do-aedes-aegypti-sc-tera-uma-semana-de-mobilizacao-para-recolhimento-de-pneus>>. Acesso em: 29 maio. 2022.
- SILVA, Ivan N. da; SPATTI, Danilo H.; FLAUZINO, Rogério A. **Redes neurais artificiais:** para engenharia e ciências aplicadas. São Paulo: Artliber: 2010
- SNELL, J. C.; ZEMEL, R. BAYESIAN FEW-SHOT CLASSIFICATION WITH ONE-VS-EACH P ´ OLYA-GAMMA AUGMENTED GAUSSIAN PROCESSES. [s.d.].
- TAKI, M. et al. Assessment of energy consumption and modeling of output energy for wheat production by neural network (MLP and RBF) and Gaussian process regression (GPR) models. **Journal of Cleaner Production**, v. 172, p. 3028–3041, 20 jan. 2018.
- TSANG, H.-H. In: Rubber: Types, Properties and Uses **USES OF SCRAP RUBBER TIRES OVERVIEW OF THE SCRAP TIRE PROBLEM.** 2010.



- **VENDAS TOTAIS DE PNEUS CRESCEM 0,4%, MAS SEGUE ACUMULANDO QUEDA NO ANO COMPARADO EM 2021 | ANIP - Associação Nacional da Indústria de Pneumáticos.** Disponível em: <<https://www.anip.org.br/releases/vendas-totais-de-pneus-crescem-04-mas-segue-acumulando-queda-no-ano-comparado-em-2021/>>. Acesso em: 20 jun. 2022.
- WANG, Y. et al. Unsupervised Learning with Generative Adversarial Network for Automatic Tire Defect Detection from X-ray Images. **Sensors 2021, Vol. 21, Page 6773**, v. 21, n. 20, p. 6773, 12 out. 2021.
- XU, Q. et al. Roadside estimation of a vehicle's center of gravity height based on an improved single-stage detection algorithm and regression prediction technology. **IEEE Sensors Journal**, 2021.
- ZHANG, T. et al. Improving Convection Trigger Functions in Deep Convective Parameterization Schemes Using Machine Learning. **Journal of Advances in Modeling Earth Systems**, v. 13, n. 5, 1 maio 2021.
- ZHU, J.; HAN, K.; WANG, S. Automobile tire life prediction based on image processing and machine learning technology: <https://doi.org/10.1177/16878140211002727>, v. 13, n. 3, p. 1–13, 11 mar. 2021.

Obrigado